

Analiza obrazów- Sprawozdanie 2

Michał Roguz, 06.12.2021r.

FIS-IS, rok 3


1. Laboratorium nr 5.

Na kolejnych laboratoriach dalej poznawaliśmy metody i algorytmy służące analizie obrazów. Tym razem przedmiotem naszych rozważań była poniższa rycina przedstawiająca kaczki.




Rys. 1. Obraz kaczek służący analizie na laboratoriach.

Tematem przewodnim zajęć była analiza za pomocą operacji morfologicznych, które pozwalały pozyskać informacje na temat własności ściśle związanych z kształtem obiektów na obrazie. W tym celu przygotowaliśmy odpowiednio obraz poddając go binaryzacji oraz inwersji.



Rys. 2. Zbinaryzowane kaczki wraz z inwersją kolorów.

Następnie przeprowadziliśmy operację zamknięcia w celu uzyskania spójnych obiektów na obrazie bez zbędnych niedoskonałości.




Rys. 3. Zbinaryzowane kaczki z inwersją barw po operacji zamknięcia.

Wszelkie późniejsze przekształcenia wykonywane są na powyższym odwzorowaniu.

Zastosowano wobec niego kolejno:


1) Operacja „remove”



Rys. 4. Obrys kaczek.

Jak widać uzyskaliśmy same kontury obiektów, które wewnątrz zostały wypełnione kolorem tła. Stało się tak, gdyż „remove” jak sama nazwa wskazuje usuwa białe piksele niesąsiadujące z czarnymi.


2) Operacje „clean” oraz „fill”



Rys. 5, 6. Kaczki z usuniętymi odchyłami.

Warto wspomnieć również o funkcjach, które niejako oczyszczają obraz. Zamieniają one w pełni odizolowane piksele centralne na wartości będące wartościami sąsiednich pikseli (zera na jedynki- fill, oraz jedynki na zera- clean). W naszym przypadku różnice wizualne są stosunkowo niewielkie.

3) Operacja „skell”



Rys. 6, 7. Kaczki sprowadzone do szkieletów z parametrem ‘szkieletyzacji’ wynoszącym kolejno 15 i nieskończoność.

Patrząc na powyższe, można zauważyć „rozpiętość” szkieletów kaczek na obrazie. Jest to nic innego jak wyznaczenie równoodległych punktów od co najmniej dwóch krawędzi obiektu.


4) Operacja „endpoints”



Rys. 8. Punkty końcowe szkieletów poszczególnych kaczek.

Wynikiem działania tej funkcji jest obraz w postaci pojedynczych punktów odpowiadających krańcom gałęzi wcześniej uzyskanych szkieletów.

5) Operacja „branchpoints”



Rys. 9. Węzły z których wychodzą poszczególne gałęzie szkieletu.

Widoczne białe kropki to punkty przecięcia linii szkieletu, z których wyprowadzane są jego gałęzie.


6) Operacja „shrink”



Rys. 10. Redukcja poszczególnych kazelek do pojedynczych punktów.

Efektem działania tej metody jest skurczenie się szkieletów do punktów stanowiących środki masy obiektów.


7) Operacja „thin”



Rys. 11, 12. Redukcja obiektów dla 20-krotnego powtórzenia wywołania, oraz maksymalnego „wychudzenia”.

Otrzymany rezultat to odcinki krzywych, które nie mogą zostać przerwane w żadnym punkcie. Redukcja przeprowadzana jest poprzez wykonanie erozji.


8) Operacja „thicken”



Rys. 13, 14. 15-krotne wywołanie funkcji `thicken`, oraz maksymalne „pogrubienie” obiektów.


Łatwo zauważyć, że powyższe odwzorowanie jest przeciwieństwem operacji „thin”. Jest to bowiem dylatacja zachowująca granice między obiektami. Widoczny jest podział na obszary, w których znajdują się obiekty.

9) Funkcja „bwlabel” wraz z „label2rgb”



Rys. 15. Każdy obiekt jest wyróżniony i wyeksponowany innym kolorem.

Funkcja ta pozwala na zaetykietowanie każdej rozróżnionej kaczki oraz nadanie każdej etykietce rozróżnialnego koloru.



Rys. 16. Wyodrębniona zaetykietowana kaczka o indeksie 2.


Dzięki zaetykietowaniu mogliśmy wyświetlać pojedyncze obiekty o poszczególnych indeksach.

10) Segmentacja z użyciem „thicken”



Rys.17. Zaetykietowana, wydzielona kaczka nr2 z tłem.


Celem wyodrębnienia kaczki razem z tłem użyliśmy wcześniej poznanej operacji „thicken”.



Rys. 18. Wydzielone segmenty obrazu.


Aby zbadać jakość segmentacji nadaliśmy etykiety i kolory każdemu wyodrębnionemu obszarowi.

11) Segmentacja wododziałowa z wykorzystaniem „bwdist”



Rys. 19. Kaczki przekształcone przez transformatę odległościową.

Ostatnim punktem zajęć była analiza wododziału uzyskanego za pomocą transformacji odległościowej. Widoczne rozgraniczenie między obiektami to tzw. wododziały, zaś ich wnętrza to zlewiska. Pikselom przyporządkowuje się odległości od najbliższych obiektów- im bliżej im będzie do obiektu tym intensywniejszy będzie ich kolor.



Rys. 20. Segmentacja wododziałowa.

Jak łatwo zauważyć, segmentację wododziałową cechuje wyższa dokładność. Wskazuje na to wygładzenie granic wydzielonych segmentów oraz brak „postrzępień”.

2. Laboratorium nr 6.

Na kolejnych zajęciach kontynuowaliśmy analizę w oparciu o własności obiektów na obrazie. Skupiliśmy się bardziej na wykorzystaniu współczynników geometrycznych celem dokładniejszego opisu obiektów. Tym razem operowaliśmy na innym zdjęciu, które przekształciliśmy do odcieni szarości.



Rys. 21. Obraz oryginalny




Rys. 22. Obraz w odcieniach szarości.

Aby poprawnie zbinaryzować obraz należało posłużyć się informacjami z poszczególnych kanałów RGB.



Rys. 23. Obraz w kanale RED.

Informację o piórach najłatwiej będzie wyłuskać z tej postaci, gdyż są one tutaj dobrze wyróżnialne.



Rys. 24. Obraz w kanale GREEN.

Kanał zielony cechuje zbyt duży gradient barw tła. Stąd nie będzie on zbyt użyteczny do dobrej binaryzacji.



Rys. 25. Obraz w kanale BLUE.


Na tym kanale doskonale odznaczają się czarne elementy kaczek, stąd jak najbardziej należy go użyć do binaryzacji.

Do przeprowadzenia efektywnej binaryzacji wykorzystaliśmy więc zarówno kanał czerwony, jak i niebieski. Każdemu z nich przyporządkowaliśmy próg binaryzacji oraz zbinaryzowaliśmy łącząc ze sobą obydwa rezultaty w jedną całość.



Rys. 26. Obraz po połączeniu binaryzacji kanałów RED oraz BLUE.

Otrzymany wynik poddaliśmy operacji otwarcia celem pozbycia się niedoskonałości.



Rys. 27. Oczyszczony obraz po binaryzacji.

Z tak przygotowanego obrazu mogliśmy już wyznaczać współczynniki geometryczne odpowiadające pewnym własnościom obiektów.

Po drodze odczytaliśmy również kilka charakterystycznych wielkości (powierzchnia, środek masy, rozpiętość obiektu, obwód, itp.) dla etykietowanych obiektów.

<input type="checkbox"/>	Area	6499
<input type="checkbox"/>	Centroid	[458.0922,524.0...
<input type="checkbox"/>	BoundingBox	[411.5000,450.5...
<input checked="" type="checkbox"/>	SubarrayIdx	1x2 cell
<input type="checkbox"/>	MajorAxisLength	133.5210
<input type="checkbox"/>	MinorAxisLength	102.1865
<input type="checkbox"/>	Eccentricity	0.6436
<input type="checkbox"/>	Orientation	-39.3388
<input type="checkbox"/>	ConvexHull	28x2 double
<input checked="" type="checkbox"/>	ConvexImage	133x149 logical
<input type="checkbox"/>	ConvexArea	11120
<input checked="" type="checkbox"/>	Image	133x149 logical
<input checked="" type="checkbox"/>	FilledImage	133x149 logical
<input type="checkbox"/>	FilledArea	6501
<input type="checkbox"/>	EulerNumber	-1
<input type="checkbox"/>	Extrema	8x2 double
<input type="checkbox"/>	EquivDiameter	90.9658
<input type="checkbox"/>	Solidity	0.5844
<input type="checkbox"/>	Extent	0.3280
<input type="checkbox"/>	PixelIdxList	6499x1 double
<input type="checkbox"/>	PixelList	6499x2 double
<input type="checkbox"/>	Perimeter	621.3470
<input type="checkbox"/>	PerimeterOld	660.2986

Rys. 28. Lista wielkości uzyskana funkcją „regionprops”.

Kolejnym krokiem było wyznaczenie kilku współczynników:

- współczynnik Blaira-Blissa- korzysta z odległości między pikselem, a środkiem masy obiektu,
- współczynnik Circularity (S lub L)- współczynnik kulistości,
- współczynnik Danielssona- opisuje go średnia odległość piksela od krawędzi,
- współczynnik Fereta- opisuje rozpiętość obiektu,
- współczynnik Haralicka- cechuje się bardzo niskim przedziałem zmienności,
- współczynnik Malinowskiej- opisuje podobieństwo figury do koła w zależności od obwodu oraz pola

	1	2	3	4	5	6	7
1	6.7399	293.4817	147.2956	134.4309	0.5000	77.3355	0.9925
2	5.9121	236.5042	119.7731	96.7954	0.9583	74.6063	0.9746
3	1.1554	2.5465	3.3851	0	1	1.2229	-0.2477
4	5.2562	183.3465	90.9658	92.7136	0.8919	53.9622	1.0156
5	6.5496	327.2226	147.0317	114.0889	0.8640	89.9930	1.2255
6	5.6362	218.6789	103.6820	88.0974	0.8023	63.2188	1.1091
7	6.1449	256.8761	123.5665	118.6441	0.7264	70.7440	1.0788
8	5.7775	182.7099	105.5140	84.7691	0.4773	57.3613	0.7316
9	3.1324	63.3437	33.3588	37.8870	2.7917	19.0407	0.8989
10	1.3275	7.3211	6.2825	10.8884	3.3333	3.1393	0.1653

Rys.29 Wyznaczone współczynniki

Jak widać, w tabelce w dwóch wierszach znajdują się dość spore odchyły od przeciętnych wartości. Zapewne obiekty te nie są gęsiami- jednym z nich jest na pewno kawałek skrzydła w prawej części obrazu, zaś drugim będzie kropka pod dwiema gęsiami w lewym dolnym rogu. By to potwierdzić dokonaliśmy standaryzacji, której wynikiem jest poniższa tabela ukazująca jako wartość logiczną 1 obiekty z odstępstwami.

	1
1	0
2	0
3	1
4	0
5	0
6	0
7	0
8	0
9	0
10	1

Rys. 30. Obiekty będące nietypowymi oznaczone logiczną 1.

3. Laboratorium nr 7

Tematem ostatnich zajęć było zagadnienie sieci neuronowej, która może pomóc w klasyfikacji nietypowych obiektów. W tym celu dokonywaliśmy analizy poniższego obrazu.



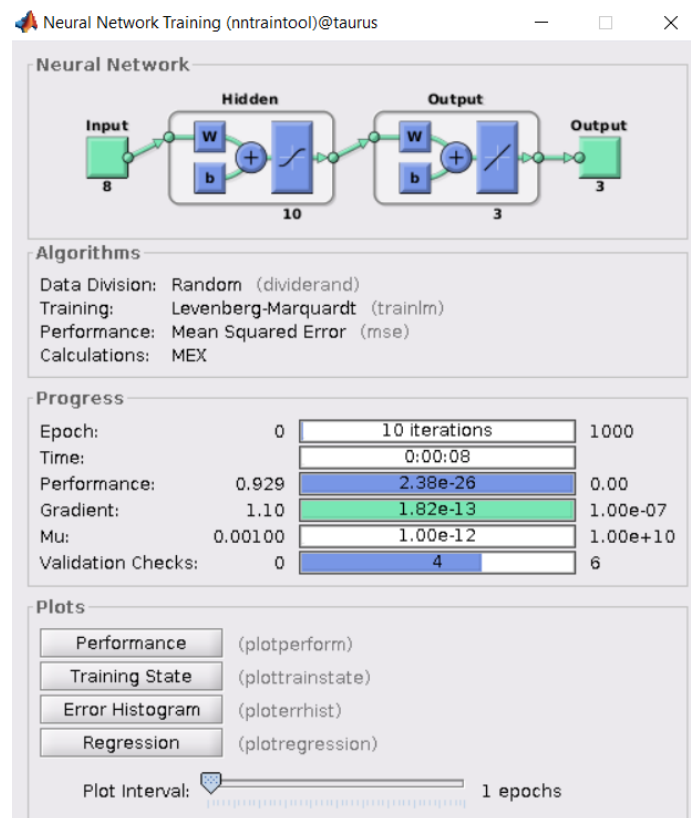
Rys. 31. Obraz służący analizie na ostatnich zajęciach.

Postąpiliśmy analogicznie jak na poprzednich zajęciach dokonując binaryzacji.




Rys. 32. Obraz po binaryzacji.

Następnie ponownie przystąpiliśmy do obliczania współczynników geometrycznych dla obrazu, które to pomogą w uczeniu sieci neuronowej. By to uczynić skorzystaliśmy z trzech utworzonych macierzy współczynników (gęsi z wysokim wsp. dopasowania z poprzednich zajęć, drugą grupą są ptaki nie wykazujące odchyłów od norm z lab.7, zaś trzecia część to nietypowe gęsi i ptaki).



Rys. 33. Okno do uczenia sieci neuronowych.



Rys. 33. Efekt uczenia sieci neuronowej na wykresie.